

Zwiększanie odporności rozpoznawania twarzy na okluzję: modyfikacje IResNet50 z mechanizmami uwagi

Raport projektowy na zajęcia
Studio Projektowe

Eliza Petrycka
Jakub Mikołajczyk

Styczeń 2026

1 Streszczenie

Systemy rozpoznawania tożsamości na podstawie obrazu twarzy osiągają imponujące wyniki dzięki nowoczesnym głębokim sieciom neuronowym i funkcjom strat opartym na marginesach kątowych, takich jak ArcFace. Ich odporność jednak zazwyczaj spada w obecności okluzji - znanego wyzwania w rzeczywistych aplikacjach, w tym systemach monitoringu, biometrii bezpieczeństwa i urządzeniach mobilnych. Niniejsza praca analizuje wpływ częściowej okluzji twarzy (zasłonięcia obszaru oczu) na dokładność identyfikacji osób oraz ocenia skuteczność modyfikacji architektur zwiększających odporność na tego typu zakłócenia.

Implementujemy i ewaluujemy trzy warianty architektur opartych na IResNet50: model bazowy, model z rozproszoną uwagą CBAM w każdym bloku rezydualnym oraz model z pomocniczą gałęzią Transformer. Ewaluacja na testowym zbiorze CASIA-WebFace z deterministyczną okluzją 20 px wskazuje, że mechanizm uwagi poprawia odporność na zasłonięcie: model z CBAM osiąga 90.16% Rank-1, przewyższając model bazowy (87.11%) o 3.05 pp. Wariant Transformer uzyskuje 85.00% Rank-1.

2 Wstęp

Rozpoznawanie tożsamości na podstawie obrazu twarzy (*ang. Face Recognition*) jest jednym z kluczowych zagadnień współczesnej wizji komputerowej i znajduje szerokie zastosowanie w systemach bezpieczeństwa, monitoringu wizyjnego oraz urządzeniach konsumenckich. W ostatnich latach, dzięki rozwojowi głębokich sieci neuronowych oraz funkcji strat opartych na marginesach kątowych, takich jak ArcFace, nowoczesne modele SOTA (State-of-the-Art) osiągają bardzo wysoką skuteczność na standardowych zbiorach testowych.

Jednocześnie skuteczność systemów rozpoznawania twarzy spada w obecności zakłóceń charakterystycznych dla rzeczywistych scenariuszy. Szczególnym wyzwaniem jest częściowa okluzja twarzy, w tym zasłonięcie obszaru oczu spowodowane noszeniem okularów, masek ochronnych lub ograniczoną widocznością w systemach monitoringu. Chociaż złożone obliczeniowo modele typu SOTA wykazują relatywnie wysoką odporność na tego typu zakłócenia, ich lepsze warianty, projektowane z myślą o zastosowaniach mobilnych, jak również starsze architektury, często charakteryzują się znacznym spadkiem skuteczności identyfikacji w warunkach okluzji.

Celem niniejszej pracy jest analiza wpływu częściowej okluzji twarzy na skuteczność systemów rozpoznawania tożsamości oraz zaproponowanie modyfikacji architektury opartej na mechanizmach uwagi, zwiększającej odporność modeli na tego typu zakłócenia.

3 Stan wiedzy

3.1 Okluzja jako źródło utraty informacji i szumu w rozpoznawaniu twarzy

Fundamentem dla zrozumienia metod radzenia sobie z niepełnymi danymi wizualnymi jest zdefiniowanie natury problemu okluzji. Jak wskazują Zeng i in. [5] w swoim przeglądzie technik rozpoznawania twarzy, okluzja stanowi dwojakie wyzwanie dla systemów biometrycznych. Po pierwsze, powoduje utratę informacji dyskryminacyjnych w obszarach zasłoniętych. Po drugie wprowadza szum (błędne cechy) pochodzący z obiektu przysyłającego (np. maski, okularów), który może zostać błędnie zinterpretowany przez sieć jako cecha tożsamościowa.

Zeng i in. proponują systematykę podejść badawczych, dzieląc je na trzy główne kategorie: (1) odporną ekstrakcję cech (*ang. Occlusion Robust Feature Extraction*), która dąży do uzyskania reprezentacji niewrażliwej na zakłócenia, często poprzez skupienie się na cechach lokalnych zamiast globalnych; (2) rozpoznawanie świadome okluzji (*ang. Occlusion Aware Face Recognition*), gdzie mechanizmy detekcji lub maskowania dynamicznie wykluczają zaszumione obszary z procesu decyzyjnego; oraz (3) rekonstrukcję okluzji (*ang. Occlusion Recovery*), polegającą na wizualnym odtworzeniu brakujących fragmentów [5].

W kontekście tej klasyfikacji, współczesna literatura coraz częściej odchodzi od prostych metod rekonstrukcji na rzecz zaawansowanego modelowania relacji przestrzennych (podejście typu 1 i 2).

3.2 Modelowanie relacji przestrzennych w warunkach niepełnych danych

Istotnym wyzwaniem w nowoczesnych systemach rozpoznawania twarzy jest odporność na degradację cech biometrycznych, wynikającą zarówno z okluzji, jak i naturalnych procesów starzenia. Choć klasyczne sieci spłotowe (CNN) skutecznie ekstrahują cechy lokalne, często napotykają trudności w modelowaniu globalnych zależności geometrycznych, gdy część danych wejściowych jest niedostępna. W tym kontekście kluczowym rozwiązaniem stają się sieci typu Transformer, zdolne do analizy zależności dalekiego zasięgu (ang. *long-range dependencies*).

Prakash i Rai [2] wykazali, że relacje przestrzenne między kluczowymi elementami twarzy pozostają stosunkowo stałe, nawet gdy powierzchniowe cechy ulegają znacznym zmianom. Zaproponowali oni podejście hybrydowe, w którym Transformer nie zastępuje głównej sieci CNN, lecz funkcjonuje jako gałąź pomocnicza z dedykowaną funkcją straty (*Transformer-Enhanced Loss*). W tej architekturze mapa cech traktowana jest jako sekwencja wektorów, co pozwala sieci skupić się na zachowanych relacjach między widocznymi fragmentami. Skuteczność tej metody potwierdzono osiągając wyniki typu State-of-the-Art na wymagających zbiorach o dużej wariancji, takich jak CA-LFW czy AgeDB.

Dla problematyki okluzji płynie stąd kluczowy wniosek: skuteczna identyfikacja twarzy częściowo przyśłoniętej nie musi polegać na wizualnej rekonstrukcji brakujących fragmentów (tzw. *inpainting*). Bardziej efektywnym podejściem jest silniejsze modelowanie wzajemnych relacji przestrzennych tych elementów, które pozostały widoczne, co pozwala utrzymać spójność reprezentacji tożsamości pomimo braku ciągłości obrazu.

3.3 Dyskryminacyjność cech w podejściu opartym na marginesach kątowych

Alternatywnym podejściem do problemu okluzji jest potraktowanie go nie jako błędu wymagającego naprawy (rekonstrukcji), lecz jako specyficznego przypadku "trudnej próbki" (ang. *hard sample*), która generuje dużą wariancję wewnątrzklasową. Wiodące badania w tym zakresie skupiają się na modyfikacji funkcji strat tak, aby wymusić silniejsze rozróżnienie (separację) pomiędzy różnymi tożsamościami w przestrzeni cech. Dzięki temu, nawet gdy część twarzy jest niewidoczna, model nadal potrafi poprawnie przypisać ją do właściwej osoby, ponieważ jej cyfrowa reprezentacja pozostaje wystarczająco unikalna.

Deng i in. [1] w swojej pracy nad metodą ArcFace (Additive Angular Margin Loss) wykazują, że standardowa funkcja straty Softmax nie jest wystarczająca do radzenia sobie z dużymi zmianami wyglądu twarzy, ponieważ nie optymalizuje bezpośrednio podobieństwa wewnątrzklasowego. Wprowadzenie addytywnego marginesu kąтового pozwala na rzutowanie cech na hipersferę, co znacząco zwiększa dyskryminacyjność modelu.

W kontekście okluzji mechanizm ten jest kluczowy: silniejsza separacja klas sprawia, że nawet jeśli wektor cech twarzy zostanie zniekształcony przez zasłonięcie fragmentu obrazu (np. oczu), wciąż ma on szansę pozostać w obrębie właściwego klastra tożsamości. Wnioski płynące z analizy ArcFace sugerują, że zwiększanie marginesu geometrycznego w funkcji straty jest skuteczną metodą poprawy odporności na brakujące cechy bez konieczności stosowania skomplikowanych mechanizmów rekonstrukcji obrazu. Dlatego też w niniejszej pracy przyjęto architekturę opartą na ArcMargin jako silny punkt odniesienia (baseline).

3.4 Redukcja zakłóceń i adaptacyjna selekcja cech za pomocą modułów uwagi (CBAM)

W kontekście rozpoznawania twarzy z okluzją kluczowym problemem jest nie tylko ekstrakcja cech, ale także umiejętność odróżnienia cech użytecznych (np. oczy, nos) od zakłóceń (np. szalik, okulary, dłonie zasłaniające twarz). Rozwiązaniem tego problemu jest zastosowanie mechanizmów uwagi, które pozwalają sieci neuronowej dynamicznie ważyć wagę poszczególnych fragmentów obrazu.

Woo i in. [4] zaproponowali moduł CBAM (Convolutional Block Attention Module), który jest lekkim i uniwersalnym rozszerzeniem dla sieci spłotowych. Istotą tego rozwiązania jest sekwencyjne wnioskowanie map uwagi w dwóch wymiarach:

1. Uwaga kanałowa (Channel Attention): Określa "co" jest ważne na obrazie. Wykorzystuje ona zarówno average-pooling (dla ogólnych statystyk), jak i max-pooling (dla cech wyróżniających), aby zdecydować, które kanały mapy cech zawierają istotne informacje o obiekcie, a które niosą szum.

2. Uwaga przestrzenna (Spatial Attention): Określa "gdzie" znajdują się istotne informacje. Jest ona komplementarna do uwagi kanałowej i pozwala sieci skupić się na lokalizacji kluczowych elementów twarzy, ignorując tło i elementy przysłaniające.

Badania przeprowadzone przez autorów, m.in. z wykorzystaniem techniki wizualizacji Grad-CAM, wykazały, że sieci wzbogacone o moduł CBAM znacznie precyzyjniej obejmują obszar docelowego obiektu. Woo i in. zauważają, że moduł ten prowadzi do redukcji szumu pochodzącego z nieistotnych elementów otoczenia (*ang. clutters*) [4]. W przypadku okluzji jest to właściwość fundamentalna – element przysłaniający twarz może zostać potraktowany przez sieć jako "nieistotny szum" (clutter) i zostać wytlumiony na etapie uwagi przestrzennej, podczas gdy widoczne fragmenty twarzy zostaną wzmocnione.

Zastosowanie CBAM jest szczególnie obiecujące w implementacji modeli odpornych na okluzję ze względu na jego modułowość. Może on być zintegrowany z dowolną architekturą CNN (np. ResNet) przy znikomym narzucie obliczeniowym, co czyni go dogodnym narzędziem do analizy wpływu selekcji cech na różnych poziomach reprezentacji.

3.5 Przegląd technik głębokiego uczenia w analizie twarzy przysłoniętych

Kompleksowe ujęcie problemu analizy twarzy z okluzją wymaga uwzględnienia nie tylko architektury sieci, ale także systematyki stosowanych metod. W najnowszym artykule przeglądowym z 2025 roku, Thaher i in. [3] wskazują, że okluzja stanowi jedno z najważniejszych otwartych wyzwań dla systemów biometrycznych, wpływając na skuteczność algorytmów rozpoznawania. Autorzy dokonują systematyzacji podejść badawczych, dzieląc istniejące rozwiązania na cztery główne kategorie:

1. **Metody oparte na cechach (*Feature-based*):** Wykorzystujące ręcznie projektowane deskryptory (np. LBP, HOG) do ekstrakcji lokalnych cech twarzy. Choć skuteczne obliczeniowo, wykazują niską odporność na niestandardowe okluzje.
2. **Metody klasycznego uczenia maszynowego (*Machine Learning-based*):** Opierające się na statystycznych modelach klasyfikacji (np. SVM, PCA), które jednak często zawodzą w przypadku złożonych, nieliniowych zakłóceń.
3. **Metody oparte na głębokim uczeniu (*Deep Learning-based*):** Wykorzystujące głębokie sieci neuronowe (CNN, Transformatory) do automatycznej ekstrakcji hierarchicznych cech. Jest to obecnie dominujący nurt, oferujący najwyższą skuteczność dzięki zdolności modelowania złożonych relacji przestrzennych.
4. **Podejścia hybrydowe (*Hybrid Approaches*):** Łączące techniki klasyczne z nowoczesnymi, np. wykorzystując analizę punktów charakterystycznych do wspierania sieci neuronowych.

Niniejsza praca osadzona jest w nurcie metod opartych na głębokim uczeniu (kategoria 3), przyjęto jednak podejście hybrydowe w rozumieniu strategii badawczej. Z jednej strony wykorzystano augmentację danych poprzez syntetyczną okluzję (zgodnie z nurtem *data-centric*), a z drugiej – zaimplementowano modyfikacje architektoniczne w postaci modułów uwagi CBAM oraz gałęzi transformatorowej (zgodnie z nurtem *model-centric*).

4 Cel i zakres projektu

4.1 Cel projektu

Celem niniejszego projektu jest analiza wpływu częściowej okluzji twarzy, ze szczególnym uwzględnieniem zasłonięcia obszaru oczu, na skuteczność systemów rozpoznawania tożsamości w zadaniu identyfikacji osób. Praca koncentruje się na ocenie odporności współczesnych modeli głębokiego uczenia na zakłócenia wizualne typowe dla rzeczywistych scenariuszy, takich jak monitoring wizyjny czy zastosowania mobilne.

W ramach projektu zaprojektowano i zaimplementowano modyfikacje architektury bazowej IResNet50 (ArcFace), polegające na integracji mechanizmu uwagi typu Convolutional Block Attention Module (CBAM) w blokach rezydualnych oraz na zastosowaniu pomocniczej gałęzi Transformer jako dodatkowej funkcji straty. Celem tych działań było zwiększenie zdolności modeli do selektywnej ekstrakcji cech dyskryminacyjnych w warunkach częściowej utraty informacji wizualnej.

Skuteczność zaproponowanych rozwiązań oceniono poprzez porównanie z wybranymi modelami typu state-of-the-art, w tym zarówno ciężkimi architekturami referencyjnymi, jak i ich lekkimi wariantami przeznaczonymi do zastosowań o ograniczonych zasobach obliczeniowych. Przeprowadzone eksperymenty umożliwiają sformułowanie wniosków dotyczących wpływu okluzji na proces identyfikacji oraz efektywności architektonicznych modyfikacji w kontekście zwiększania odporności modeli na tego typu zakłócenia.

4.2 Zakres pracy

Zakres pracy obejmuje analizę problemu rozpoznawania twarzy na podstawie obrazów 2D w warunkach częściowej okluzji, ze szczególnym uwzględnieniem syntetycznego zasłonięcia obszaru oczu. Badania przeprowadzono z wykorzystaniem wybranego zbioru danych zawierającego obrazy twarzy poddane procedurze wyrównania (alignment) oraz kontrolowanej augmentacji w postaci okluzji.

W ramach projektu wykonano:

- * porównanie wybranych modeli typu state-of-the-art (ArcFace Large, ArcFace Small, VGGFace) z autorskimi implementacjami opartymi na architekturze IResNet50,
- * analizę wpływu rozproszonej uwagi CBAM (integracja w blokach rezydualnych) na skuteczność identyfikacji,
- * analizę wpływu pomocniczej gałęzi Transformer na odporność na okluzję,
- * ocenę skuteczności strategii transfer learningu i fine-tuningu w kontekście odporności na okluzję,
- * ewaluację modeli w zadaniu identyfikacji tożsamości z wykorzystaniem metryk Rank-1 oraz Rank-3.

Zakres pracy ograniczono do porównania modelu bazowego oraz jego modyfikowanych wariantów architektonicznych. Nie przeprowadzono analizy alternatywnych rodzin modeli (np. w pełni transformatorych), metod wymagających dodatkowych modalności biometrycznych ani zaawansowanych technik rekonstrukcji okluzji.

Projekt nie obejmuje analizy danych wideo, danych trójwymiarowych (3D), zagadnień związanych z detekcją twarzy, ani optymalizacji modeli pod kątem wdrożeń produkcyjnych w systemach czasu rzeczywistego. Detekcja twarzy została wykorzystana wyłącznie jako etap wstępnego wyrównania danych wejściowych i nie stanowi przedmiotu analizy ani porównań w niniejszej pracy. Ponadto badania ograniczono do eksperymentów z wykorzystaniem syntetycznie generowanej okluzji, bez walidacji na rzeczywistych zbiorach danych zawierających naturalne przesłonięcia twarzy.

5 Metodologia

Niniejsza sekcja opisuje metodologię zastosowaną w opracowaniu i ocenie modeli rozpoznawania twarzy z naciskiem na niezawodność wobec okluzji. Szczegółowo omawiamy przygotowanie danych, architektury modeli, procedury treningowe i protokoły ewaluacji.

5.1 Przygotowanie danych i przetwarzanie wstępne

5.1.1 Przegląd datasetu

Badania przeprowadzono na zbiorze danych CASIA-WebFace, zawierającym ponad 494 tys. kolorowych fotografii twarzy, należących do 10,575 unikatowych tożsamości. Dane podzielono na dwa rozłączne podzbiory: treningowy (90%) i testowy (10%). Dla monitorowania zbieżności modelu wykorzystywano stały zestaw 500 par (walidacja) z części testowej, zgodnie z pipeline’em treningowym.

5.1.2 Wyrównanie na podstawie punktów orientacyjnych

Wszystkie obrazy są wstępnie przetwarzane za pomocą modelu RetinaFace od InsightFace w celu wykrycia 5 punktów orientacyjnych twarzy: lewe oko, prawe oko, czubek nosa i kąciki ust. Te punkty orientacyjne umożliwiają konsistentną normalizację twarzy przy użyciu transformacji podobieństwa do standardowej rozdzielczości 112×112 . Większość obrazów ma towarzyszący plik zawierający:

- Współrzędne ramki ograniczającej: $\text{bbox} = [x_1, y_1, x_2, y_2]$

- 5 punktów orientacyjnych: `landmarks = {lewe_oko, prawe_oko, nos, lewy_ust, prawy_ust}`

W przypadku braku punktów szczególnych twarzy, zastosowano skalowanie obrazu do 112×112 . Brak pliku wynikał z niepowodzenia detekcji punktów orientacyjnych dla niskiej jakości lub nietypowych obrazów (ok. 2,5% zdjęć).

Wyrównanie twarzy jest wykonywane przy użyciu referencyjnej konfiguracji punktów orientacyjnych:

$$M = \text{Similarity_Transform}(\text{wykryte_punkty}, \text{punkty_referencyjne}) \quad (1)$$

gdzie punkty referencyjne dla obrazów 112×112 są ustalone na:

$$\text{arcface_dest} = \begin{bmatrix} 38.29 & 51.70 \\ 73.53 & 51.50 \\ 56.03 & 71.74 \\ 41.55 & 92.37 \\ 70.73 & 92.20 \end{bmatrix} \quad (2)$$

Punkty te stanowią standardową konfigurację stosowaną w ArcFace i zostały zaczerpnięte z dokumentacji kodu oryginalnego modelu, gdzie określono je jako referencyjne pozycje cech twarzy w wyrównanych obrazach.

Ta procedura zapewniła konsystentne wyrównanie zgodne z oryginalnym modelem Buffalo_L (ArcFace Large), co jest kluczowe dla transferu wag.

5.1.3 Strategia augmentacji danych

Wszystkie modele są trenowane z syntetyczną okluzją w celu symulacji zasłonięć w regionie oczu. Implementacja stosuje poziomy pasek okluzji o stałej wysokości i losowym kolorze.

- **Wysokość:** 20 pikseli
- **Szerokość:** pełna szerokość obrazu (0 do 112)
- **Pozycja pionowa:** $y = 52 \pm 5$ pikseli (region oczu)
- **Kolor:** losowe RGB (r, g, b) , $r, g, b \in [0, 255]$

Prawdopodobieństwo wystąpienia okluzji różni się między wariantami zgodnie z kodem treningowym:

- **Baseline:** $p = 0.7$
- **Transformers:** $p = 0.7$
- **CBAM_Block:** $p = 0.5$

W fazie testowej kolor okluzji jest stały (czarny), co zapewnia powtarzalność i porównywalność wyników pomiędzy modelami.

5.2 Ewaluacja modeli typu SOTA

W celu rzetelnego punktu odniesienia dla uzyskanych wyników przeprowadzono ewaluację wybranych modeli typu state-of-the-art (SOTA), w tym modeli dostępnych w bibliotece InsightFace oraz modelu referencyjnego.

Wybrane modele obejmowały zarówno rozwiązania o wysokiej dokładności, jak i lekkie architektury zoptymalizowane pod kątem wydajności obliczeniowej, a także model referencyjny starszej generacji.

Testowane modele:

- ArcFace Large (`buffalo_l`) – model oparty na architekturze IResNet-50, dostępny w bibliotece InsightFace,
- ArcFace Small (`buffalo_s`) – lekka architektura oparta na MobileFaceNet, przeznaczona do zastosowań mobilnych, dostępna w bibliotece InsightFace,



Rysunek 1: Przykładowe zdjęcia ze zbioru danych po nałożeniu okluzji i wyrównaniu

- VGGFace2 (ResNet-50) – model referencyjny starszej generacji (2018 r.), zaimplementowany z wykorzystaniem biblioteki *keras-vggface*, niebędący częścią frameworka InsightFace.

Wszystkie modele poddano temu samemu protokołowi identyfikacji (galeria–sonda) oraz symulacji okluzji w postaci poziomego zasłonięcia regionu oczu o wysokości 20 pikseli. Należy jednak podkreślić, że część modeli SOTA wykorzystuje własny pipeline ekstrakcji cech: dla ArcFace (InsightFace) embeddingi są wyznaczane na podstawie pełnego obrazu z detekcją twarzy, natomiast dla VGGFace (ResNet50) stosowane jest przycięcie względem *bbox* i skalowanie do 224×224 . Zostało to utrzymane zgodnie z implementacjami referencyjnymi w repozytorium. Szczegółowy opis protokołu ewaluacji przedstawiono w dalszej części dokumentu.

5.3 Model bazowy

5.3.1 Wybór IResNet50

Wybraliśmy IResNet50 (Ulepszona sieć ResNet50) jako architekturę sieci głównej ze względu na jej sprawdzoną wydajność w modelu ArcFace-Large (*buffalo_1*) z projektu InsightFace. IResNet50 składa się z:


- Wstępna konwolucja: 3×3 conv, 64 kanały, stride 1
- Warstwy 1-4: Bloki resztkowe o różnych głębokościach
- Normalizacja wsadowa i aktywacje PReLU na całej sieci
- Wymiar cechy: embeddingi 512-wymiarowe

5.3.2 Hybrydowa strategia transferu wag

Bezpośredni transfer z modelu *buffalo_1* opartego na ONNX do PyTorch okazał się trudny ze względu na niezgodności architektoniczne. Zastosowano hybrydowe dopasowanie wag (dopasowanie nazw + dopasowanie kształtu), z reinicjalizacją warstw bez dopasowania. Proces ten zapewnia stabilny punkt startowy dla fine-tuningu.

Pomyślne transfery: $\approx 90\%$ wag bloków ResNet zostało pomyślnie zmapowanych, w tym:

- Warstwy Conv2d w ścieżkach resztkowych
- Większość parametrów BatchNorm (wagi, obciążenia, statystyki uruchamiające)
- Wagi PReLU (gdzie konwencje nazewnictwa się zgadzały)



Rysunek 2: Architektura sieci IResNet50

Warstwy reinicjalizowane: 26 warstw wymagało inicjalizacji Kaiming Normal (He) ze względu na niezgodność architektoniczną:

- layer1.2.bn3: statystyki BatchNorm3D (running_mean, running_var)
- layer2.3.bn2, layer2.3.bn3: parametry BatchNorm
- layer2.3.prelu: waga PReLU (parametr α)
- layer3.12-13.bn2-3: podobne instancje BatchNorm i PReLU

Formuła inicjalizacji:

$$w \sim \mathcal{N}(0, \sqrt{\frac{2}{n_{in}(1 + a^2)}}) \quad (3)$$

gdzie a jest ujemnym nachyleniem (0 dla ReLU, 0.25 dla PReLU w naszym przypadku - później trenowane).

5.4 Funkcje straty

5.4.1 Strata ArcMargin

Podstawową funkcją straty w modelu bazowym oraz w wariancie CBAM_Block (model z CBAM) jest strata ArcMargin, marginalna strata softmax, która wymusza separowalność kątową w przestrzeni osadzania. W implementacji przyjęto parametry $m = 0.5$ i $s = 30.0$ (zbieżne z ArcFace).

W treningu optymalizowana jest standardowa *CrossEntropy* na wyjściu ArcMargin:

$$\mathcal{L}_{\text{ArcFace}} = \text{CE}(\text{ArcMargin}(\mathbf{e}), y) \quad (4)$$

5.4.2 Strata złożona dla wariantu Transformer

W wariancie Transformer zastosowano funkcję straty łączoną, gdzie gałąź podstawowa (ArcMargin) jest wzbogacana o pomocniczą stratę klasyfikacji z transformera (CrossEntropy):

$$\mathcal{L}_{\text{total}} = (1 - \alpha) \mathcal{L}_{\text{ArcFace}} + \alpha \mathcal{L}_{\text{Trans}} \quad (5)$$


gdzie $\alpha = 0.4$ zgodnie z parametrami w kodzie treningu.

5.5 Modyfikacja Architektury: Strategie Odporności na Okluzję

Zaproponowane modyfikacje architektury ograniczono do wariantów faktycznie obecnych w implementacji. Wszystkie modele bazują na IResNet50 i różnią się wyłącznie dodatkowymi mechanizmami odporności na okluzję.


Wariant A: Model bazowy Wariant odniesienia wykorzystuje standardowy backbone IResNet50 oraz głowicę ArcMargin do klasyfikacji tożsamości. Nie stosuje mechanizmów uwagi ani dodatkowych głowic pomocniczych. Jego rolą jest stanowić stabilny punkt odniesienia do oceny wpływu modyfikacji architektury.

Wariant B: CBAM zintegrowany w blokach rezydualnych W tym wariantcie moduły CBAM umieszczono wewnątrz każdego bloku rezydualnego (CBAMBasicBlock), bezpośrednio przed połączeniem rezydualnym. Zastosowano uwagę kanałową i przestrzenną, co pozwala na selektywne wzmacnianie istotnych map cech na wielu poziomach abstrakcji. Celem wariantu jest uzyskanie odporności na okluzję poprzez rozproszoną filtrację zakłóceń.



Rysunek 3: Schemat systemu CBAM. Źródło: [4]

Wariant C: Gałąź pomocnicza Transformer Wariant ten modyfikuje backbone tak, aby zwracał mapę cech o rozmiarze 7×7 , a następnie dodaje pomocniczą gałąź Transformer (Branch-2) uczoną równolegle z głowicą ArcMargin (Branch-1). W trakcie treningu wykorzystywana jest strata łączona (ArcMargin + CrossEntropy z gałęzi Transformer), natomiast podczas ewaluacji wykorzystywana jest wyłącznie gałąź standardowa.



Rysunek 4: Architektura dwugałęziowa z uczeniem metrycznym i wspomaganie Transformerem. Źródło: [2]

5.5.1 Strategia uczenia i stabilizacji

We wszystkich wariantach zastosowano transfer learning z wagami wstępnie wytrenowanymi, a w wariantcie CBAM_Block dodatkowo etapowe zamrażanie/odmrażanie wag w celu stabilizacji uczenia. Augmentacja danych obejmowała syntetyczną okluzję regionu oczu, spójną z protokołem ewaluacyjnym.

5.6 Procedura Treningu

5.6.1 Model bazowy

Model bazowy trenowany jest jako klasyfikator z głowicą ArcMargin.

Hiperparametr	Wartość
Rozmiar partii	32
Epoki	max 25
Optymalizator	SGD (momentum=0.9)
LR	1×10^{-2}
Zanik wag	brak (nie ustawiono)
Wczesne zatrzymanie	Tak (patience=5)
Walidacja	500 par z testu (Rank-1)
Augmentacja okluzji	$p = 0.7$, wysokość 20 px

Tabela 1: Hiperparametry modelu bazowego

5.6.2 Gałąź pomocnicza Transformer

Model z transformatorem wykorzystuje złożoną funkcję straty, łącząc ArcMargin i klasyfikację gałęzi pomocniczej.

Hiperparametr	Wartość
Rozmiar partii	32
Epoki	max 25
Optymalizator	SGD (momentum=0.9, weight_decay= 5×10^{-4})
LR	1×10^{-2}
ALPHA (balans strat)	0.4
Transformer layers/heads	6 / 8
Wczesne zatrzymanie	Tak (patience=5)
Walidacja	500 par z testu (Rank-1)
Augmentacja okluzji	$p = 0.7$, wysokość 20 px

Tabela 2: Hiperparametry modelu z gałęzią Transformer.

5.6.3 CBAM_Block (uwaga w każdym bloku)

Trening realizowany jest dwuetapowo z zamrożeniem backbone'u w pierwszej epoce.

Hiperparametr	Wartość
Rozmiar partii	64
Epoki	max 30
Optymalizator	SGD (momentum=0.9, weight_decay= 5×10^{-4})
LR start	0.1
Harmonogram LR	StepLR (step_size=10, gamma=0.1)
Zamrażanie	Epoka 1: tylko CBAM + head
Walidacja	500 par z testu (Rank-1)
Augmentacja okluzji	$p = 0.5$, wysokość 20 px

Tabela 3: Hiperparametry modelu CBAM_Block.

5.7 Protokół ewaluacji

5.7.1 Konstrukcja zestawu testowego

Protokół ewaluacji stosuje zadanie identyfikacji galeria-vs-sonda:

Zestaw galerii: Skonstruowany z pierwszej połowy zdjęć dla każdej osoby w podziale testowym. Dla każdej osoby embeddingi z wielu czystych (nie okluzjowanych) obrazów są uśredniane:

$$\mathbf{e}_{\text{gallery}} = \frac{1}{n} \sum_{i=1}^n \text{L2-Normalize}(\mathbf{e}_i) \quad (6)$$

Zapewnia to niezawodny prototyp osoby do dopasowania podobieństwa.

Zestaw sondy: Skonstruowany z drugiej połowy zdjęć. Te obrazy są poddane syntetycznej okluzji podczas ewaluacji (szczegóły w sekcji 5.7.3).

5.7.2 Ekstrakcja embeddingu i indeksowanie

1. Ekstrahuj embedding dla wszystkich obrazów galerii i sondy
2. Normalizuj L2: $\hat{e} = \frac{e}{\|e\|_2}$
3. Indeksuj embedding galerii przy użyciu FAISS IndexFlatIP (Inner Product), gdzie podobieństwo cosinusowe na wektorach znormalizowanych L2 równa się iloczynowi wewnętrznemu

Rozdział walidacji i ewaluacji: w trakcie treningu stosowana jest pomocnicza walidacja na 500 parach (średnia cosinusowa czyste vs okluzjowane), próbkowanych z części testowej. Wyniki Rank-1/Rank-3 pochodzą z niezależnego pipeline'u FAISS dla zadania identyfikacji galeria-vs-sonda.

Wyjaśnienie: Rola biblioteki FAISS i metryki Inner Product W procesie ewaluacji wykorzystano bibliotekę FAISS (Facebook AI Similarity Search), która stanowi standard przemysłowy w zadaniach wydajnego przeszukiwania podobieństwa w zbiorach wielowymiarowych. Do indeksowania wektorów cech (embeddingów) zastosowano indeks `IndexFlatIP`, który realizuje wyszukiwanie w oparciu o iloczyn wewnętrzny (ang. *Inner Product*). Wybór ten jest bezpośrednią konsekwencją właściwości funkcji straty ArcFace, która operuje na wektorach zrzutowanych na hipersferę. Ponieważ wszystkie wektory cech są poddawane normalizacji L2 (ich długość wynosi 1), iloczyn skalarny dwóch wektorów u i v staje się matematycznie równoważny ich podobieństwu cosinusowemu, zgodnie ze wzorem:

$$u \cdot v = \|u\| \|v\| \cos \theta = 1 \cdot 1 \cdot \cos \theta = \cos \theta.$$

Dzięki temu zastosowanie szybkiej operacji mnożenia macierzowego w FAISS pozwala na uzyskanie wyników tożsamyh z metryką cosinusową, przy znaczącym wzroście wydajności obliczeniowej.

5.7.3 Symulacja okluzji w ewaluacji

Podczas ewaluacji każdy obraz sondy jest syntetycznie okluzjowany przy użyciu deterministycznego protokołu, aby zapewnić powtarzalność:

- **Wysokość okluzji:** 20 pikseli
- **Szerokość okluzji:** jeśli dostępny `bbox` z adnotacji, pasek ograniczany jest do zakresu $[x_1, x_2]$; w przeciwnym razie pełna szerokość obrazu (0 do 112)
- **Kolor:** Czarny (0,0,0) [deterministyczny, w przeciwieństwie do losowej augmentacji treningowej]
- **Pozycja pionowa:** Region oczu, obliczony z punktów orientacyjnych:

$$c_y = \frac{y_{lewe_oko} + y_{prawe_oko}}{2} = 51.6 \quad (7)$$

- **Zakres Y:** $[c_y - 10, c_y + 10]$

W procedurze ewaluacyjnej zastosowano deterministyczną okluzję w postaci czarnego paska, aby zapewnić pełną powtarzalność i porównywalność wyników testowych, eliminując losowość wynikającą z wariacji kolorystycznych obecnych w fazie treningu.

Wyrównanie w ewaluacji: obrazy testowe w zbiorze `webface_112x112` są już wstępnie wyrównane.

5.7.4 Wyszukiwanie podobieństwa i metryki

Dla każdego obrazu sondy p :

1. Zapytaj indeks FAISS z $k = 3$ najbliższymi sąsiadami
2. Pobierz top-3 tożsamości galerii ze wynikami podobieństwa: (s_1, s_2, s_3)

Dokładność Rank-k:

$$\text{Rank-}k = \frac{\# \text{ zapytań z prawidłową tożsamością w top-}k}{N_{\text{ogółem}}} \quad (8)$$

W szczególności:

- **Dokładność Rank-1:** $P(\text{tożsamość}[0] = \text{rzeczywistość})$
- **Dokładność Rank-3:** $P(\text{rzeczywistość} \in \{\text{tożsamość}[0, 1, 2]\})$

5.7.5 Wyjście i logowanie

Szczegółowe wyniki są logowane w formacie CSV z kolumnami:

```
1 query_id, top1_id, sim1, top2_id, sim2, top3_id, sim3
```

5.8 Środowisko obliczeniowe i implementacja

Wszystkie eksperymenty zostały przeprowadzone w środowisku Python z wykorzystaniem PyTorch do trenowania modeli, InsightFace do detekcji punktów orientacyjnych oraz FAISS do szybkiego wyszukiwania podobieństwa w przestrzeni embedding'ów (kod źródłowy projektu ¹). Dla modeli autorskich zastosowano wspólny pipeline danych (wyrównanie, augmentacja, normalizacja, ekstrakcja embedding'ów), co minimalizuje ryzyko różnic wynikających z niejednorodnych procedur wejściowych. Modele SOTA korzystały z własnych, referencyjnych pipeline'ów zgodnie z implementacjami w repozytorium.

Modelowanie architektur odbywało się w tym samym szkieletcie IResNet50, a modyfikacje ograniczano do ściśle kontrolowanych miejsc (gałąź pomocnicza Transformer lub moduły CBAM). Taka polityka zmian pozwala przypisać obserwowane różnice wydajności wyłącznie wprowadzonym mechanizmom odporności na okluzję.

5.9 Dobór hiperparametrów i stabilność uczenia

Wybór hiperparametrów oparto na konserwatywnym dostrajaniu: najpierw ustalono stabilny punkt odniesienia (baseline), następnie wprowadzono modyfikacje architektury (CBAM_Block i Transformer) przy zachowaniu porównywalnego pipeline'u danych. Dla wariantu CBAM_Block stosowano harmonogram StepLR oraz etapowe zamrażanie/odmrażanie warstw, a dla pozostałych wariantów wczesne zatrzymanie na podstawie walidacji (500 par) w celu ograniczenia niestabilności numerycznej.

Parametry uczenia (rozmiar partii, epoki, współczynniki uczenia) dobrano empirycznie na podstawie obserwowanej zbieżności funkcji straty i stabilności średniej cosinusowej na zbiorze walidacyjnym (500 par z części testowej). Jednolity protokół augmentacji (okluzja w rejonie oczu) utrzymano we wszystkich wariantach, co umożliwia bezpośrednie porównanie modeli.

5.10 Reprodukowalność i logowanie

W kodzie nie ustawiono stałych ziaren losowości, dlatego przebiegi mogą wykazywać niewielką wariancję między uruchomieniami. Dla każdego wariantu zachowywano najlepszy checkpoint według wyników z walidacji, a końcowa ewaluacja wykonywana była wyłącznie na ustalonym zbiorze testowym z deterministyczną okluzją.

6 Wyniki

Niniejsza sekcja prezentuje wyniki ewaluacji modeli rozpoznawania twarzy na testowym zbiorze CASIA-WebFace, ze szczególnym uwzględnieniem ich odporności na okluzję. Wartości Rank-1/Rank-3 pochodzą z zapisów wygenerowanych przez pipeline FAISS w scenariuszu okluzji 20px. Wyniki zawierają porównanie dokładności Rank-k, analizę wpływu syntetycznej okluzji oraz porównanie z modelami SOTA.

¹<https://github.com/Studio-Projektowe/Face-recognition-with-occlusion/tree/main>

6.1 Porównanie z modelami SOTA

W celu ustalenia benchmarku, poddaliśmy testowaniu trzy modele stanowiące stan techniki w rozpoznawaniu twarzy: ArcFace Large (buffalo_l), ArcFace Small (buffalo_s) oraz VGGFace (model legacy). Wszystkie modele testowano w identycznym scenariuszu okluzji (syntetyczna okluzja 20 pikseli na poziomie oczu). Wyniki zawarto w Tabeli 4.

Model	Rank-1 (%)	Rank-3 (%)
ArcFace Large (buffalo_l)	94.81	95.51
ArcFace Small (buffalo_s)	86.65	90.68
VGGFace (Legacy)	39.64	57.01

Tabela 4: Wyniki modeli SOTA na zbiorze testowym z syntetyczną okluzją 20px.

ArcFace Large wyznacza górny limit wydajności (94.81%), przy czym model wykorzystuje masywny dataset treningowy (MS1MV2 z ~ 5.8 M obrazów). ArcFace Small (86.65%) stanowi punkt odniesienia dla efektywnych modeli przemysłowych. VGGFace (39.64%) pokazuje drastyczną degradację, podkreślając znaczenie nowoczesnych funkcji straty opartych na marginesach (ArcFace) w porównaniu do starszych podejść opartych na softmax.

6.2 Dokładność modeli badawczych z okluzją

Modele własne obecne w repozytorium obejmują wariant bazowy, wariant z CBAM w blokach rezydualnych oraz wariant z gałęzią Transformer. Wyniki Rank-1 i Rank-3 przedstawiono w Tabeli 5.

Model	Rank-1 (%)	Rank-3 (%)	Delta vs Baseline
Baseline	87.11	90.56	–
CBAM_Block	90.16	91.88	+3.05 pp
Transformers	85.00	89.02	-2.11 pp

Tabela 5: Dokładność modeli badawczych na zbiorze testowym z syntetyczną okluzją 20px.

Najlepsze wyniki wśród modeli badawczych osiągnął wariant CBAM_Block (90.16%), przekraczając baseline o 3.05 pp. Wariant Transformer uzyskał niższy wynik niż baseline.

6.3 Analiza degradacji wydajności

Porównanie wyników modeli w scenariuszu okluzji, nieznaczenie, ale potwierdza, że rozproszona uwaga (CBAM_Block) zwiększa odporność na zasłonięcie kluczowych regionów. Model ArcFace Large osiąga 94.81% w warunkach okluzji 20px, podczas gdy najlepszy wariant badawczy CBAM_Block uzyskuje 90.16%.

6.4 Ranking modeli

W celu analizy zachowania top-k zestawiono różnice Rank-3 vs Rank-1. Najmniejszą lukę uzyskano dla ArcFace Large i CBAM_Block, co może wskazywać na stabilniejsze dopasowania.

Model	Rank-1 (%)	Rank-3 (%)	Luka Rank-3 - Rank-1
ArcFace Large (buffalo_l)	94.81	95.51	0.70
CBAM_Block	90.16	91.88	1.72
Baseline	87.11	90.56	3.45
ArcFace Small (buffalo_s)	86.65	90.68	4.03
Transformers	85.00	89.02	4.02
VGGFace (Legacy)	39.64	57.01	17.37


Tabela 6: Luka pomiędzy Rank-3 i Rank-1 dla wszystkich modeli.

6.5 Analiza jakościowa map uwagi

W celu głębszego zrozumienia mechanizmów decyzyjnych badanych modeli, przeprowadzono wizualizację map aktywacji klas (Grad-CAM) dla przykładowej próbki z okluzją regionu oczu (Rysunek 5). Analiza heatmap pozwala zweryfikować, czy modele nauczyły się ekstrahować cechy tożsamości z widocznych fragmentów twarzy, ignorując syntetyczne zakłócenie.

Jak widać na załączonych wizualizacjach, wszystkie trzy warianty wykazują pożądaną tendencję do omijania czarnego paska okluzji, koncentrując uwagę na niezaburzonych obszarach. Można jednak zaobserwować istotne w rozkładzie uwagi:

- **Model bazowy (Rys. 5a)** wykazuje aktywność punktową, skupioną głównie na nosie i fragmencie czoła, jednak mapa uwagi jest stosunkowo rozproszona i mniej spójna.
- **Model z Transformerami (Rys. 5c)** silnie koncentruje się na górnej części twarzy (czoło, brwi) powyżej paska okluzji, w mniejszym stopniu wykorzystując informacje z dolnych partii twarzy.
- **Model z CBAM (Rys. 5b)** generuje mapę uwagi o największym pokryciu powierzchni twarzy. Mechanizm uwagi przestrzennej (Spatial Attention) pozwolił sieci na efektywną eksplorację wszystkich dostępnych, niezakłóconych regionów, w tym policzków, nosa oraz ust.



Rysunek 5: Porównanie map aktywacji (Grad-CAM) dla trzech wariantów przy okluzji oczu.

7 Dyskusja

W tej sekcji omawiamy to, co udało nam się osiągnąć w testach. Patrzymy na te wyniki krytycznie, bo na końcowe liczby wpłynęło kilka ważnych czynników, które pojawiły się w trakcie pracy nad projektem.

7.1 Interpretacja wyników i dobór parametrów

W naszych testach model CBAM_Block wypadł najlepiej, osiągając dokładność Rank-1 na poziomie 90.16%. Jest to wynik o 3.05 punktu procentowego lepszy niż w przypadku modelu bazowego (87.11%).

Musimy tutaj wyraźnie zaznaczyć, że te liczby to nie są wyniki z pojedynczych, przypadkowych uruchomień. Przeprowadziliśmy bardzo dużo prób z różnymi zestawami hiperparametrów (hyperparameter tuning), testując różne wartości współczynnika uczenia oraz intensywność augmentacji. W raporcie pokazujemy tylko te najlepsze konfiguracje, jakie udało nam się wypracować dla każdego modelu.

Trzeba jednak uczciwie przyznać, że te "najlepsze" ustawienia różniły się między modelami, co utrudnia ich bezpośrednie porównanie:

- **Współczynnik uczenia (LR):** Model CBAM potrzebował 10-krotnie wyższego LR (0.1), żeby w ogóle zacząć się dobrze uczyć. Baseline najlepiej działał przy LR równym 0.01. Ta różnica mogła pomóc modelowi CBAM szybciej "naprawić" błędy wynikające z losowej inicjalizacji części wag.
- **Częstotliwość okluzji (p):** Najlepszy wynik CBAM uzyskaliśmy przy $p = 0.5$, podczas gdy Baseline najlepiej radził sobie przy $p = 0.7$. Oznacza to, że model CBAM w trakcie treningu widział więcej "czystych" zdjęć, co na pewno ułatwiło mu naukę rozpoznawania cech twarzy.

Model z Transformerem wypadł najslabiej (85.00%). Podejrzewamy, że dodatkowa funkcja straty z gałęzi pomocniczej wprowadziła zbyt dużo "szumu" i sieć nie zdołała się ustabilizować w ciągu założonych 25 epok.

7.2 Problemy z Transfer Learningiem

Dużym wyzwaniem okazał się sam proces przenoszenia modelu z formatu ONNX do PyTorch. Przez to, że nie wszystkie warstwy (aż 26, w tym statystyki BatchNorm) przeniosły się poprawnie, musieliśmy je zainicjalizować losowo.

To sprawiło, że nasz model bazowy (Baseline) nie był tak silny, jak oryginalny Buffalo_L. Można więc powiedzieć, że model CBAM nie tyle dodał nową wiedzę, co po prostu lepiej poradził sobie z wyjściem z tej osłabionej pozycji dzięki agresywnemu strojeniu parametrów.

7.3 Wizualizacja uwagi (Grad-CAM)

Mimo problemów z parametrami, mapy **Grad-CAM** (Rys. 5) pokazują coś ciekawego. Model CBAM faktycznie potrafi "omijać" czarny pasek na oczach i szukać cech niżej – na ustach czy policzkach. W modelu bazowym to skupienie uwagi było bardziej chaotyczne. To potwierdza, że mechanizm CBAM teoretycznie działa tak, jak zakładaliśmy.

8 Wnioski

Na podstawie naszych prac wyciągnęliśmy następujące wnioski:

1. **Potencjał modułów uwagi:** Moduły CBAM faktycznie pomagają sieci skupić się na istotnych częściach twarzy, gdy oczy są zasłonięte, co pozwoliło nam dobić do 90% skuteczności.
2. **Znaczenie procesu treningu:** Nasze doświadczenia pokazały, że to, jak ustawimy parametry (LR, augmentacja), ma czasem większy wpływ na wynik niż sama zmiana architektury sieci.
3. **Wyzwania techniczne:** Poprawny Transfer Learning jest kluczowy. Błędy na etapie wczytywania wag zmuszają do bardzo czasochłonnego strojenia modelu "od zera".

Co można zrobić lepiej? W przyszłości chcielibyśmy powtórzyć te testy na identycznych ustawieniach dla wszystkich modeli, żeby wynik był w 100% sprawiedliwy. Warto też sprawdzić, jak sieć poradzi sobie z realnymi przeszkodami (np. maseczkami medycznymi na zbiorze MAFA), a nie tylko z syntetycznymi czarnymi paskami.

Literatura

- [1] J. Deng, J. Guo, J. Yang, N. Xue, I. Kotsia, and S. Zafeiriou. Arcface: Additive angular margin loss for deep face recognition. *arXiv preprint arXiv:1801.07698*, 2018.
- [2] P. Prakash and A. K. Rai. Age-defying face recognition with transformer-enhanced loss. 2025. W publikacji (Preprint/Artykuł).
- [3] T. Thaher, M. Mafarja, M. Saffarini, A. H. H. M. Mohamed, and A. A. El-Saleh. A comprehensive review of face detection techniques for occluded faces: Methods, datasets, and open challenges. *Computer Modeling in Engineering & Sciences*, 144(1), 2025.
- [4] S. Woo, J. Park, J.-Y. Lee, and I. S. Kweon. Cbam: Convolutional block attention module. In *Proceedings of the European Conference on Computer Vision (ECCV)*, 2018.
- [5] D. Zeng, R. Veldhuis, and L. Spreeuwers. A survey of face recognition techniques under occlusion. *arXiv preprint arXiv:2006.11366*, 2020.

A Szczegóły architektury CBAM

A.1 Moduł uwagi kanałów

Moduł uwagi kanałów (CAM) oblicza wagi uwagi dla każdego kanału poprzez agregację wymiarów przestrzennych:

A.1.1 Moduł uwagi kanałów

Moduł uwagi kanałów (Channel Attention Module) generuje mapę wag $\mathbf{M}_c \in \mathbb{R}^{C \times 1 \times 1}$ poprzez eksploatację zależności międzykanałowych. Proces ten wykorzystuje współdzielony MLP operujący na zagregowanych przestrzennie cechach:

$$\mathbf{M}_c(\mathbf{F}) = \sigma(W_1(\text{ReLU}(W_0(\mathbf{F}_{\text{avg}}^c))) + W_1(\text{ReLU}(W_0(\mathbf{F}_{\text{max}}^c)))) \quad (9)$$

gdzie:

- $\mathbf{F}_{\text{avg}}^c, \mathbf{F}_{\text{max}}^c$ oznaczają wektory cech uzyskane odpowiednio przez Average Pooling i Max Pooling przestrzenny.
- $W_0 \in \mathbb{R}^{C/r \times C}$ oraz $W_1 \in \mathbb{R}^{C \times C/r}$ to wagi współdzielonej sieci MLP (bottleneck), a r jest współczynnikiem redukcji.
- σ oznacza funkcję aktywacji sigmoidalną.

Ostatecznie, mapa cech jest modyfikowana poprzez mnożenie elementarne (z broadcastowaniem wzdłuż wymiarów przestrzennych):

$$\mathbf{F}' = \mathbf{M}_c(\mathbf{F}) \otimes \mathbf{F} \quad (10)$$

A.2 Moduł uwagi przestrzennej

Moduł uwagi przestrzennej (SAM) generuje mapy uwagi przestrzennej poprzez łączenie uśredniania kanałów i max pooling:

$$\text{SAM}(\mathbf{X}) = \sigma(\text{Conv}_{7 \times 7}([\text{AvgPool}(\mathbf{X}); \text{MaxPool}(\mathbf{X})])) \quad (11)$$

gdzie:

- $[\cdot; \cdot]$ = łączenie kanałów (wejście: $h \times w \times 2$)
- $\text{Conv}_{7 \times 7}$ = pojedyncza konwolucja 7×7 z 1 kanałem wyjścia
- σ = aktywacja sigmoidalna

Uwaga przestrzenna jest zastosowana jako:

$$\mathbf{X}'' = \text{SAM}(\mathbf{X}') \otimes \mathbf{X}' \quad (12)$$

A.3 Kompletny blok CBAM

Kompletny blok CBAM łączy oba mechanizmy uwagi w sekwencji:

$$\begin{aligned} \mathbf{F}' &= \mathbf{M}_c(\mathbf{F}) \otimes \mathbf{F} \\ \mathbf{F}'' &= \mathbf{M}_s(\mathbf{F}') \otimes \mathbf{F}' \end{aligned} \quad (13)$$

$$\mathbf{Y} = \mathbf{F}'' + \mathbf{X} \quad (14)$$

W architekturach resztkowych CBAM jest stosowany przed operacją dodawania resztkowego:

$$\mathbf{Y} = \text{CBAM}(\text{Conv}(\mathbf{X})) + \mathbf{X} \quad (15)$$

Dla IResNet50 zastosowano wariant **Block-wise (CBAM_Block)**: moduł CBAM jest wstawiony we-
wnątrz każdego bloku resztkowego, co umożliwia hierarchiczną filtrację zakłóceń na wielu poziomach.

B Tabele uzupełniające

B.1 Podsumowanie kompletnych konfiguracji modeli

Model	Partia	Epoki	LR	Optimizer	Harmonogram
Baseline	32	25	1×10^{-2}	SGD (mom=0.9)	–
Transformers	32	25	1×10^{-2}	SGD (mom=0.9, wd= 5×10^{-4})	–
CBAM_Block	64	30	0.1	SGD (mom=0.9, wd= 5×10^{-4})	StepLR(10, 0.1)

Tabela 7: Podsumowanie konfiguracji treningowych modeli obecnych w repozytorium.

B.2 Mapowanie wariantów architektury na mechanizmy odporności

Wariant	Mechanizm	Miejsce integracji	Dodatkowa strata
Baseline	Brak	–	Nie
CBAM_Block	Uwaga kanałowa + przestrzenna	W każdym bloku resztkowym	Nie
Transformers	Gałąź Transformer	Po mapie cech 7×7	Tak (CE, $\alpha = 0.4$)

Tabela 8: Zestawienie wariantów architektury i mechanizmów odporności na okluzję.

B.3 Parametry funkcji straty

Komponenta straty	Model	Konfiguracja
Strata ArcMargin	Baseline, CBAM_Block	$m = 0.5, s = 30.0$
Strata ArcMargin	Transformers	$m = 0.5, s = 30.0$ (gałąź główna)
Strata Transformer (CE)	Transformers	$\alpha = 0.4$ w stracie złożonej

Tabela 9: Konfiguracja funkcji straty dla modeli obecnych w repozytorium.

C Definicja metryk ewaluacji

Dla zestawu testowego z N całkowitymi zapytaniami sondy:

$$\text{Dokładność Rank-1} = \frac{1}{N} \sum_{i=1}^N \mathbb{K}[\text{top_1}[i] = \text{gt}[i]] \quad (16)$$

$$\text{Dokładność Rank-3} = \frac{1}{N} \sum_{i=1}^N \mathbb{K}[\text{gt}[i] \in \{\text{top_1}, \text{top_2}, \text{top_3}\}[i]] \quad (17)$$

gdzie $\mathbb{K}[\cdot]$ jest funkcją wskaźnika, a $\text{gt}[i]$ jest rzeczywistą tożsamością dla zapytania i .

D Statystyki datasetu

Podział	Obrazy	Tożsamości
Trenowanie	442 710	9 514
Test (Galeria)	24 227	1 057
Test (Sonda)	24 227	1 057

Tabela 10: Statystyki podziału datasetu CASIA-WebFace.